



ANALIZA STATISTICĂ A PERSONAJELOR DIN GAME OF THRONES

REZUMAT

Explorarea factorilor care influențează soarta personajelor folosind tehnici statistice precum Chi-Square, ANOVA și Pearson.

Ana-Maria Brânzea

Proiect Analiza Datelor

Cuprins

1. Descrierea problemei	3
2. Elemente teoretice privind tehnicile utilizate în proiect.....	3
➤ Chi-Square Test	3
➤ ANOVA (Analiza Varianței)	4
➤ Pearson's r Test (Coeficientul de corelație Pearson)	5
3. Sursa de date	6
➤ Preprocesarea datelor	6
4. Rezultate obținute și interpretarea acestora	7
➤ Analize Grafice	7
➤ Analiza Testelor Statistice	12
Testul Chi-Square: Gender vs Nobility	12
Testul ANOVA: Book Intro Chapter vs Allegiances	13
Testul Pearson: Book of Death vs Gender	13
5. Concluzii.....	14
Referințe bibliografice	16

Lista figuri

Figură 1- Eliminare duplicate.....	6
Figură 2-Adăugare valoare pentru Allegiances.....	6
Figură 3-Adăugare valoare pentru personajele în viață	7
Figură 4-Adăugare valoare pentru personajele în viață (Book of Death&Death Chapter)	7
Figură 5- Codul sursă pentru analiza numărului de decese în funcție de nobilitate	7
Figură 6-Graficul "Number of Deaths by Nobility"	7
Figură 7- Codul sursă pentru numărului de decese în funcție de gen	8
Figură 8- Graficul "Number of Deaths by Gender"	8
Figură 9-Codul sursă pentru distribuția personajelor în funcție de apartenența la o casă	9
Figură 10-Graficul "Distribution of Characters by Allegiances"	9
Figură 11-Codul sursă pentru distribuția deceselor în funcție de capitolele cărților	10
Figură 12-Graficul "Distribution of Death Chapters"	10
Figură 13-Codul sursă pentru distribuția deceselor în funcție de apartenență și gen	11
Figură 14-Graficul "Deaths by Allegiance and Gender".....	11
Figură 15-Testul Chi-Square: Gender vs Nobility.....	12
Figură 16-Testul ANOVA	13
Figură 17-Testul Pearson's R.....	14

1. Descrierea problemei

Proiectul are ca scop analiza datelor referitoare la personajele din seria de cărți *Game of Thrones*, care oferă informații despre moartea acestora și diverse caracteristici precum sexul, nobilimea și alianțele. Scopul principal este de a explora și vizualiza distribuția morților în funcție de factori precum anul morții, sexul, nobilimea și alianțele, utilizând tehnici de procesare a datelor, grafice, dar și analize statistice pentru a răspunde la întrebări precum:

- Care este distribuția morților în funcție de sex?
- Cum sunt distribuite personajele în funcție de alianțe?
- Care este corelația între genul unui personaj și capitolul în care moare?

Prin analiza setului de date, proiectul propune să evidențieze tendințele și să ofere o înțelegere mai mare asupra dinamicii personajelor din *Game of Thrones*.

2. Elemente teoretice privind tehnicile utilizate în proiect

➤ Chi-Square Test

Testul Chi-pătrat este utilizat pentru a verifica relația dintre două variabile categorice. Poate fi folosit pentru a compara frecvențele observate cu cele așteptate sub ipoteza nulă. Există două aplicații principale:

- **Testul de ajustare Chi-pătrat:** Verifică dacă distribuția unui eșantion se potrivește cu o distribuție teoretică specifică (de exemplu, dacă un set de date urmează o distribuție uniformă).
- **Testul de independență Chi-pătrat:** Verifică dacă două variabile categorice sunt independente sau nu (de exemplu, dacă fumatul este legat de nivelul de educație).

Ipotezele:

- **Ipoteza nulă (H0):** Nu există relație între variabilele studiate (sunt independente).
- **Ipoteza alternativă (H1):** Există o relație între variabilele studiate (nu sunt independente).

Calcul:

Testul Chi-pătrat se calculează cu formula:

$$\chi^2 = \sum_{i=1}^n \frac{(O_i - E_i)^2}{E_i}$$

unde:

- O_i este frecvența observată,
- E_i este frecvența așteptată.

Dacă valoarea calculată a lui Chi-pătrat este mai mare decât valoarea critică din distribuția Chi-pătrat pentru un anumit nivel de semnificație și grade de libertate, ipoteza nulă este respinsă.

Grade de libertate:

Gradele de libertate pentru testul Chi-pătrat se calculează ca:

$$df = (q - 1) \times (r - 1)$$

unde r este numărul de rânduri și c este numărul de coloane din tabelul de contingență.

➤ ANOVA (Analiza Varianței)

Analiza Varianței (ANOVA) este o tehnică statistică folosită pentru a testa dacă există diferențe semnificative între mediile a trei sau mai multe grupuri. Această metodă se bazează pe compararea variabilității între grupuri cu variabilitatea din interiorul grupurilor pentru a evalua dacă diferențele observate între medii sunt suficient de mari pentru a fi semnificative din punct de vedere statistic.

Ipotezele testului ANOVA

- **Ipoteza nulă (H_0):** Toate mediile grupurilor sunt egale, adică nu există diferențe semnificative între grupuri.
- **Ipoteza alternativă (H_1):** Cel puțin una dintre mediile grupurilor este diferită de celelalte.

Pentru ca testul ANOVA să fie valid, trebuie să îndeplinească câteva presupuneri:

1. Observațiile din fiecare grup de tratament trebuie să fie independente și să provină din eșantioane aleatorii.
2. Populațiile trebuie să fie distribuite normal.
3. Variațiile între grupuri trebuie să fie omogene, adică să aibă aceleași varianțe (presupunerea de homoscedasticitate).

Tipuri de ANOVA

1. **One-way ANOVA (ANOVA unidirecțională):** Testează diferențele dintre mediile a trei sau mai multe grupuri, având un singur factor de interes.
2. **Two-way ANOVA (ANOVA bidirecțională):** Testează diferențele între grupuri având două variabile de interes, luând în considerare și interacțiunea dintre aceste variabile.

Calculul testului ANOVA

ANOVA se bazează pe raportul dintre media pătratelor între grupuri și media pătratelor în interiorul grupurilor. Mai exact, testul ANOVA se calculează astfel:

$$F = \frac{MSB}{MSW}$$

unde:

- MSB (Mean Square Between groups) reprezintă media pătratelor între grupuri,
- MSW (Mean Square Within groups) reprezintă media pătratelor în interiorul grupurilor.

Dacă raportul F este suficient de mare, adică mai mare decât valoarea critică din distribuția F pentru un anumit nivel de semnificație și grade de libertate, atunci ipoteza nulă se respinge, iar concluzia este că există diferențe semnificative între mediile grupurilor.

Gradele de libertate

- **df între grupuri (df_1):** Calculat ca $k-1$, unde k este numărul de grupuri.
- **df în interiorul grupurilor (df_2):** Calculat ca $N-k$, unde N este numărul total de observații.

➤ Pearson's r Test (Coeficientul de corelație Pearson)

Coeficientul de corelație Pearson (denumit și Pearson's r) măsoară forța și direcția relației liniare dintre două variabile continue. Este un indicator al cât de bine se potrivesc variabilele într-o relație liniară.

Intervalul de valori:

- **$r = 1$:** Corelație pozitivă perfectă – pe măsură ce o variabilă crește, cealaltă crește în mod proporțional.
- **$r = -1$:** Corelație negativă perfectă – pe măsură ce o variabilă crește, cealaltă scade în mod proporțional.
- **$r = 0$:** Nu există nici o corelație liniară între variabile.

Calcul:

Coeficientul Pearson se calculează folosind formula:

$$r = \frac{\sum xy - N\bar{x}\bar{y}}{\sqrt{(\sum x^2 - N\bar{x}^2)(\sum y^2 - N\bar{y}^2)}}$$

unde:

- x și y sunt valorile celor două variabile,
- n este numărul de observații.

Semnificația:

Pentru a evalua semnificația coeficientului de corelație, se utilizează un test t, unde ipoteza nulă este că nu există corelație între variabile (adică $r=0$ sau $0r=0$). Testul t se calculează astfel:

$$t = \frac{r\sqrt{N-2}}{\sqrt{1-r^2}}$$

Apoi, se compară valoarea t cu valoarea critică din distribuția t pentru a decide dacă corelația este semnificativă.

Grade de libertate:

$$df = N - 2$$

3. Sursa de date

Pentru acest proiect, am utilizat un fișier CSV intitulat `character-deaths.csv` (preluat de pe platforma [Kaggle](#)), care conține informații detaliate despre personajele din seria Game of Thrones. Datele sunt structurate în coloane specifice, fiecare oferind informații esențiale despre caracteristicile și evenimentele legate de personajele respective. Coloanele din acest fișier sunt următoarele:

- **Name:** Numele personajului.
- **Allegiances:** Casa de care aparține personajul.
- **Death Year:** Anul în care a murit personajul.
- **Book of Death:** Cartea în care a murit personajul.
- **Death Chapter:** Capitolul din cartea în care a murit personajul.
- **Book Intro Chapter:** Capitolul din carte în care a fost introdus personajul.
- **Gender:** Genul personajului (1 reprezintă masculin, 0 reprezintă feminin).
- **Nobility:** Statutul nobil al personajului (1 reprezintă nobil, 0 reprezintă om de rând).
- **GoT:** Apariția personajului în prima carte (1 dacă a apărut, 0 dacă nu a apărut).
- **CoK:** Apariția personajului în a doua carte (1 dacă a apărut, 0 dacă nu a apărut).
- **SoS:** Apariția personajului în a treia carte (1 dacă a apărut, 0 dacă nu a apărut).
- **FfC:** Apariția personajului în a patra carte (1 dacă a apărut, 0 dacă nu a apărut).
- **DwD:** Apariția personajului în a cincea carte (1 dacă a apărut, 0 dacă nu a apărut).

➤ Preprocesarea datelor

Analizând datele din csv, am observat că există anumite date lipsă pentru coloanele `Allegiances`, `Death Year`, `Book of Death`, `Death Chapter`, `Book Intro Chapter`, așadar, le-am tratat astfel:

- Am eliminat duplicatele pentru a asigura unicitatea fiecărui personaj

```
got_prep=got.drop_duplicates()
```

Figură 1- Eliminare duplicate

- Am adăugat valoarea “unknown” pentru coloana 'Allegiances'

```
got_prep['Allegiances']=got_prep['Allegiances'].fillna('unknown')
```

Figură 2-Adăugare valoare pentru Allegiances

- Am presupus că personajele care nu au un an al morții Death Year, sunt în viață, deci am adăugat valoarea 0.

```
got_prep['Death Year']=got_prep['Death Year'].fillna(0)
got_prep['Death Year']=got_prep['Death Year'].astype('int')
```

Figură 3-Adăugare valoare pentru personajele în viață

- Pentru 'Book of Death' și 'Death Chapter' am adăugat valori diferite (valori de -1) pentru a indica că personajele sunt încă în viață

```
got_prep['Book of Death']=got_prep['Book of Death'].fillna('-1')
got_prep['Death Chapter']=got_prep['Death Chapter'].fillna('-1')
```

Figură 4-Adăugare valoare pentru personajele în viață (Book of Death&Death Chapter)

4. Rezultate obținute și interpretarea acestora


➤ Analize Grafice

I. Analiza numărului de decese în funcție de nobilitate

Pentru a înțelege distribuția deceselor în rândul personajelor nobile și al oamenilor de rând, am utilizat un grafic de tip barplot. Am numărat câte personaje nobile și câți oameni de rând au murit și am reprezentat aceste valori grafic.

```
''' How does the number of deaths compare between commoners and nobility in Game of Thrones? '''
death_nobility = got_prep[got_prep['Death Year'] > 0]['Nobility'].value_counts()
plt.figure(figsize=(4, 2))
sns.barplot(x=death_nobility.index, y=death_nobility.values)
plt.title('Number of Deaths by Nobility')
plt.xlabel('Status')
plt.ylabel('Number of Deaths')
plt.xticks([0, 1], ['Commoner', 'Nobility'])
plt.show()
```

Figură 5- Codul sursa pentru analiza numărului de decese în funcție de nobilitate



Figură 6-Graficul "Number of Deaths by Nobility"

Se observă că oamenii de rând au un număr mai mare de decese, deci putem spune că războaiele au avut un impact asupra populației generale.


II. Analiza numărului de decese în funcție de gen

Am analizat distribuția deceselor în funcție de genul personajelor, folosind din nou un grafic de tip barplot.

```
''' How does the number of deaths compare between male and female characters in Game of Thrones? '''

death_gender = got_prep[got_prep['Death Year'] > 0]['Gender'].value_counts()
plt.figure(figsize = (4, 2))
sns.barplot(x = death_gender.index, y = death_gender.values)
plt.title('Number of Deaths by Gender')
plt.xlabel('Gender')
plt.ylabel('Number of Deaths')
plt.xticks([0, 1], ['Male', 'Female'])
plt.show()
```

Figură 7- Codul sursă pentru numărului de decese în funcție de gen



Figură 8- Graficul "Number of Deaths by Gender"

Se observă că mai mult de 200 de bărbați au murit, în timp ce numărul de femei decedate este sub 100.


III. Distribuția personajelor în funcție de apartenența la o casă (Allegiances)

Am reprezentat distribuția personajelor în funcție de loialitatea lor față de diverse case nobiliare printr-un grafic de tip barplot.

```
''' How many characters belong to each allegiance in Game of Thrones? '''
# Count the number of characters for each allegiance
allegiances_count = got_prep['Allegiances'].value_counts()

# barplot
plt.figure(figsize=(6, 3))
sns.barplot(x=allegiances_count.index, y=allegiances_count.values)
plt.title('Distribution of Characters by Allegiances')
plt.xlabel('Allegiances')
plt.ylabel('Number of Characters')
plt.xticks(rotation=90) # Rotate x-axis labels for better readability
plt.show()
```

Figură 9-Codul sursă pentru distribuția personajelor în funcție de apartenența la o casă



Figură 10-Graficul "Distribution of Characters by Allegiances"

Un număr foarte mare de personaje nu aparțin niciunei alianțe (Unknown), presupunând astfel că sunt independente. Următoarea categorie cu cei mai mulți membri este *Night's Watch*, având sens deoarece casa recrutează membrii din toate alianțele, fiind compus foști criminali, violatori sau exilați.


IV. Distribuția deceselor în funcție de capitolele cărților

Pentru a observa în ce capitole apar cele mai multe decese, am creat o histogramă cu numărul de decese raportat la capitolele cărților.

```
''' How are character deaths distributed across book chapters in Game of Thrones? '''
# Filter out only valid values (exclude -1)
filtered_data = got_prep[got_prep['Death Chapter'] != -1]

# Create histogram
plt.figure(figsize=(8, 5))
sns.histplot(filtered_data['Death Chapter'], bins=40, kde=False, color='blue')
plt.title("Distribution of Death Chapters")
plt.xlabel("Death Chapter")
plt.ylabel("Frequency")
plt.show()
```

Figură 11-Codul sursă pentru distribuția deceselor în funcție de capitolele cărților



Figură 12-Graficul "Distribution of Death Chapters"

Graficul arată că decesele nu sunt distribuite uniform pe parcursul cărților. Există niște vârfuri în anumite capitole ceea ce înseamnă că moartea personajelor se întâmplă în anumite momente-cheie ale poveștii, cum ar fi bătălii sau evenimente majore (ex. Red Wedding, Battle of the Bastards). Vârfurile de la capitolele 20, 30, 50 și 70 arată că acestea sunt momente intense.


V. Distribuția deceselor în funcție de apartenență și gen

Am utilizat un grafic cu bare stivuite pentru a reprezenta distribuția deceselor în funcție de apartenența la o casă și gen.

```
'''What is the distribution of deaths by allegiance and gender in Game of Thrones?'''
# Group the data by Allegiances and gender
gender_alliance_deaths = got_prep.groupby(['Allegiances', 'Gender']).size().unstack()

# stacked bar chart
plt.figure(figsize=(12, 6))
gender_alliance_deaths.plot(kind='bar', stacked=True, color=['lightblue', 'lightpink'])
plt.title("Deaths by Allegiance and Gender")
plt.xlabel("Allegiance")
plt.ylabel("Number of Deaths")
plt.xticks(rotation=45)
plt.legend(title="Sex")
plt.show()
```

Figură 13-Codul sursă pentru distribuția deceselor în funcție de apartenență și gen



Figură 14-Graficul "Deaths by Allegiance and Gender"

Graficul arată numărul de decese pentru fiecare alianță, împărțite pe gen (roz pentru **femei** și albastru pentru **bărbați**).

➤ Analiza Testelor Statistice

Testul Chi-Square: Gender vs Nobility

- Ipoteze:
 - » H_0 : Genul nu influențează statutul nobiliar.
 - » H_1 : Genul influențează statutul nobiliar.
- Rezultate:
 - » *Chi-square statistic*: **3.01**
 - » *P-value*: **0.0826** (mai mare decât 0.05)
 - » Degrees of freedom: 1
 - » Expected frequencies:
 - Nobili: **83.38 bărbați, 73.62 femei**
 - Non-nobili: **403.62 bărbați, 356.38 femei**
- Concluzie: Nu respingem ipoteza nulă (fail to reject H_0). Aceasta înseamnă că nu există o legătură semnificativă între gen și statutul nobiliar în Game of Thrones.

```
#CHI-SQUARE test
'''
H0: Gender has no effect on Nobility.
H1: Gender has an effect on Nobility.
'''

from scipy.stats import chi2_contingency
# Define a function to perform Chi-square test
def chi_square_test(feature1, feature2, alpha=0.05):
    contingency_table = pd.crosstab(got_prep[feature1], got_prep[feature2])
    chi2, p, dof, expected = chi2_contingency(contingency_table)
    #return chi2, p
    print(f"{feature1} vs {feature2}:")
    print(f"Chi-square statistic: {chi2}")
    print(f"P-value: {p}")
    print(f"Degrees of freedom: {dof}")
    print(f"Expected frequencies:\n{expected}")

# Interpret results
if p < alpha:
    print("\nConclusion: Reject H0. There is an effect between gender and nobility.")
else:
    print("\nConclusion: Fail to reject H0. There is no significant effect between gender and nobility.")

# Gender vs Nobility
chi_square_test('Gender', 'Nobility')
#print(f"Gender vs Nobility: Chi-square statistic: {chi2}, P-value: {p}")

Gender vs Nobility:
Chi-square statistic: 3.0120843723385438
P-value: 0.08264595331843264
Degrees of freedom: 1
Expected frequencies:
[[ 83.37949836  73.62050164]
 [403.62050164 356.37949836]]

Conclusion: Fail to reject H0. There is no significant effect between gender and nobility.
```

Figură 15-Testul Chi-Square: Gender vs Nobility

Testul ANOVA: Book Intro Chapter vs Allegiances

- Ipoteze:
 - » H_0 : Alianța unui personaj nu influențează capitolul în care este introdus.
 - » H_1 : Alianța unui personaj influențează capitolul în care este introdus.
- Rezultate:
 - » F -statistic: **3.22**
 - » P -value: **2.52e-06** (mult mai mic decât 0.05)
- Concluzie: Se respinge ipoteza nulă (reject H_0). Acest lucru indică faptul că există diferențe semnificative între capitolul de introducere a personajelor în funcție de alianța lor (Allegiances).

```
import scipy.stats as stats
#ANOVA
'''
H0: There are no significant differences in Book Intro Chapter across different Allegiances.
H1: There are significant differences in Book Intro Chapter across different Allegiances.
'''

#clean the dataset
filtered_data = got_prep.dropna(subset=['Book Intro Chapter', 'Allegiances'])

# group by allegiances
grouped_data = [filtered_data[filtered_data['Allegiances'] == allegiance]['Book Intro Chapter']
                 for allegiance in filtered_data['Allegiances'].unique()]

# Perform one-way ANOVA
f_stat, p_value = stats.f_oneway(*grouped_data)

# Display results
print("ANOVA Results:")
print(f"F-Statistic: {f_stat}")
print(f"P-Value: {p_value}")

# Interpret results
if p_value < 0.05:
    print("\nConclusion: Reject H0. There are significant differences in Book Intro Chapter across different Allegiances.")
else:
    print("\nConclusion: Fail to reject H0. There are no significant differences in Book Intro Chapter across different Allegiances.")

ANOVA Results:
F-Statistic: 3.2243934016868296
P-Value: 2.516502880008535e-06

Conclusion: Reject H0. There are significant differences in Book Intro Chapter across different Allegiances.
```

Figură 16-Testul ANOVA

Testul Pearson: Book of Death vs Gender

- Ipoteze:
 - » H_0 : Nu există o corelație semnificativă între Book of Death și Gender.
 - » H_1 : Există o corelație semnificativă între Book of Death și Gender.
- Rezultate:
 - » Pearson's R (coeficient de corelație): **0.0729**
 - » P -value: **0.0274** (mai mic decât 0.05)
- Concluzie: Respingem ipoteza nulă (H_0). Aceasta înseamnă că există o corelație între Book of Death și Gender, deși coeficientul de corelație nu este foarte mare.

```

#PEARSON'S R TEST
'''
H0: There is no significant correlation between Book of Death and Gender.
H1: There is a significant correlation between Book of Death and Gender.
'''

# Clean dataset for analysis
filtered_data = got_prep.dropna(subset=['Book of Death', 'Gender'])

# Split data
book_of_death = filtered_data['Book of Death']
gender = filtered_data['Gender']

# Pearson's R
r, p_value = stats.pearsonr(book_of_death, gender)

# Display results
print("Pearson's R Test:")
print(f"Correlation Coefficient (R): {r}")
print(f"P-Value: {p_value}")

# Interpret results
if p_value < 0.05:
    print("\nConclusion: Reject H0. There is a significant correlation between Book of Death and Gender.")
else:
    print("\nConclusion: Fail to reject H0. No significant correlation between Book of Death and Gender.")

Pearson's R Test:
Correlation Coefficient (R): 0.07285132524130465
P-Value: 0.027383501379590957

Conclusion: Reject H0. There is a significant correlation between Book of Death and Gender.

```

Figură 17-Testul Pearson's R

5. Concluzii

Proiectul de analiză a datelor privind personajele din seria de cărți *Game of Thrones* a avut ca scop examinarea diverselor aspecte legate de personaje, cum ar fi distribuția acestora în funcție de gen, nobilitate și alianțe. Cu ajutorul tehnicilor de procesare a datelor, graficelor și analizei statistice, am obținut informații relevante care ne-au ajutat la înțelegerea mai detaliată a poveștii și a structurii acesteia.

1. Distribuția Deceselor în Funcție de Gen și Nobilitate

Am observat că numărul femeilor decedate este mult mai mic decât cel al bărbaților, fiind de așteptat deoarece bărbații sunt implicați de cele mai multe ori în bătălii. De asemenea, am remarcat că oamenii de rând au murit într-un număr mai mare decât cei nobili, războaiele având un impact semnificativ în această privință.

2. Distribuția Personajelor în Funcție de Alianțe

Analiza apartenenței personajelor la diverse case a arătat că majoritatea nu aparțin unei alianțe anume, multe dintre ele fiind înregistrate cu valoarea „Unknown” (valoare adăugată în preprocesarea datelor), sugerând astfel că aceste personaje sunt independente. Totuși, casa

Night's Watch are un număr mare de membri față de celelalte alianțe, având în vedere modul lor de a recruta membri din diverse colțuri ale lumii.

3. Testele Statistice

- **Testul Chi-Square (Gen vs Nobilitate):** Nu am putut respinge ipoteza nulă, ceea ce înseamnă că nu există o relație semnificativă între gen și statutul nobil.
- **Testul ANOVA (Gen vs Capitolul de Introducere):** Rezultatele sugerează că alianța din care face parte un personaj influențează semnificativ capitolul de introducere al acestuia în serie.
- **Testul Pearson (Cartea Morții vs Gen):** Deși corelația este destul de slabă, am respins ipoteza nulă, însemnând că există o corelație semnificativă între gen și cartea în care moare un personaj.

Concluzie Generală

În concluzie, în urma analizei efectuate am reușit să identific diverse tendințe și corelații între trăsăturile personajelor și modul în care acestea își întâlnesc sfârșitul în *Game of Thrones*. Acest proiect mi-a arătat că o analiză asupra unei baze de date este foarte importantă pentru a înțelege mai bine relațiile complexe dintre atribute.

Referințe bibliografice

1. The Chi squared tests, Thebmj, <https://www.bmj.com/about-bmj/resources-readers/publications/statistics-square-one/8-chi-squared-tests>
2. MODELE STATISTICE ÎN ANALIZA VARIAȚIEI (ANOVA),
<http://inf.ucv.ro/documents/danciulescu/MCE-informatica/Curs%205%20MCE.pdf>
3. PEARSON'S R, CHI-SQUARE, T-TEST, AND ANOVA,
https://us.sagepub.com/sites/default/files/upm-binaries/33663_Chapter4.pdf
4. Note curs, https://timf.upg-ploiesti.ro/cursuri/cursuri/AD/note_curs.pdf
5. Mohammed J. Zaki, Wagner Meira, Jr., Data Mining and Machine Learning: Fundamental Concepts and Algorithms, 2nd Edition, Cambridge University Press, March 2020. ISBN: 978-1108473989, <https://dataminingbook.info/book.html/>
6. Central Limit Theorem and the Law of Large Numbers Class 6, 18.05 Jeremy Orloff and Jonathan Bloom, <https://math.mit.edu/~dav/05.dir/class6-prep.pdf>
7. Central Limit Theorem and the Law of Large Numbers Class 6, 18.05 Jeremy Orloff and Jonathan Bloom, <https://math.mit.edu/~dav/05.dir/class6-prep.pdf>

Anexe

```
import os
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.decomposition import PCA

# Set the aesthetic style of the plots
sns.set_style('whitegrid')

got = pd.read_csv('/content/drive/MyDrive/DataSets/character-deaths.csv')
got
got.shape
got.info()
got.describe(include='all')
got.isnull().sum()

# --- Data preprocessing ---
# Removing duplicates
got_prep=got.drop_duplicates()
got_prep

#add 0 to "death year" where values are missing (characters are still alive)

got_prep['Death Year']=got_prep['Death Year'].fillna(0)
got_prep['Death Year']=got_prep['Death Year'].astype('int')
#got_prep

#schimb tipul de data col 'gender' in boolean
got_prep['Gender']=got_prep['Gender'].astype('bool')

#schimb tipul de data col 'Nobility' in boolean
got_prep['Nobility']=got_prep['Nobility'].astype('bool')
got_prep.info()
got_prep
```

ANALIZA STATISTICĂ A PERSONAJELOR DIN GAME OF THRONES

```
#add 'unknown' to the 'Allegiances' column where the values are missing
got_prep['Allegiances']=got_prep['Allegiances'].fillna('unknown')

got_prep.isnull().sum()

# for 'book of death' and 'death chapter' assign a different value to
indicate that the characters are still alive

got_prep['Book of Death']=got_prep['Book of Death'].fillna('-1')
got_prep['Death Chapter']=got_prep['Death Chapter'].fillna('-1')
got_prep['Book Intro Chapter']=got_prep['Book Intro Chapter'].fillna('1')

#make them int
got_prep['Book of Death']=got_prep['Book of Death'].astype('int')
got_prep['Death Chapter']=got_prep['Death Chapter'].astype('int')
got_prep['Book Intro Chapter']=got_prep['Book Intro Chapter'].astype('int')
got_prep.info()

got_prep.isnull().sum()

''' How does the number of deaths compare between commoners and nobility in
Game of Thrones? '''

death_nobility = got_prep[got_prep['Death Year'] >
0]['Nobility'].value_counts()

plt.figure(figsize=(4, 2))

sns.barplot(x=death_nobility.index, y=death_nobility.values)

plt.title('Number of Deaths by Nobility')

plt.xlabel('Status')

plt.ylabel('Number of Deaths')

plt.xticks([0, 1], ['Commoner', 'Nobility'])

plt.show()

''' How does the number of deaths compare between male and female characters
in Game of Thrones? '''

death_gender = got_prep[got_prep['Death Year'] > 0]['Gender'].value_counts()

plt.figure(figsize = (4, 2))

sns.barplot(x = death_gender.index, y = death_gender.values)

plt.title('Number of Deaths by Gender')

plt.xlabel('Gender')

plt.ylabel('Number of Deaths')

plt.xticks([0, 1], ['Female', 'Male'])

plt.show()
```

ANALIZA STATISTICĂ A PERSONAJELOR DIN GAME OF THRONES

```
''' How many characters belong to each allegiance in Game of Thrones? '''

# Count the number of characters for each allegiance
allegiances_count = got_prep['Allegiances'].value_counts()

# barplot
plt.figure(figsize=(6, 3))
sns.barplot(x=allegiances_count.index, y=allegiances_count.values)
plt.title('Distribution of Characters by Allegiances')
plt.xlabel('Allegiances')
plt.ylabel('Number of Characters')
plt.xticks(rotation=90) # Rotate x-axis labels for better readability
plt.show()

''' How are character deaths distributed across book chapters in Game of
Thrones? '''

# Filter out only valid values (exclude -1)
filtered_data = got_prep[got_prep['Death Chapter'] != -1]

# Create histogram
plt.figure(figsize=(6, 3))
sns.histplot(filtered_data['Death Chapter'], bins=40, kde=False,
color='blue')

plt.title("Distribution of Death Chapters")
plt.xlabel("Death Chapter")
plt.ylabel("Frequency")
plt.show()

'''What is the distribution of deaths by allegiance and gender in Game of
Thrones?'''

# Group the data by Allegiances and gender
gender_alliance_deaths = got_prep.groupby(['Allegiances',
'Gender']).size().unstack()

# stacked bar chart
plt.figure(figsize=(12, 6))

gender_alliance_deaths.plot(kind='bar', stacked=True, color=['lightpink',
'lightblue'])

plt.title("Deaths by Allegiance and Gender")
```

ANALIZA STATISTICĂ A PERSONAJELOR DIN GAME OF THRONES

```
plt.xlabel("Allegiance")
plt.ylabel("Number of Deaths")
plt.xticks(rotation=45)
plt.legend(title="Sex")
plt.show()

#statistical analysis
#CHI-SQUARE test
'''
H0: Gender has no effect on Nobility.
H1: Gender has an effect on Nobility.
'''

from scipy.stats import chi2_contingency
# Define a function to perform Chi-square test
def chi_square_test(feature1, feature2, alpha=0.05):
    contingency_table = pd.crosstab(got_prep[feature1], got_prep[feature2])
    chi2, p, dof, expected = chi2_contingency(contingency_table)
    #return chi2, p
    print(f"{feature1} vs {feature2}:")
    print(f"Chi-square statistic: {chi2}")
    print(f"P-value: {p}")
    print(f"Degrees of freedom: {dof}")
    print(f"Expected frequencies:\n{expected}")

# Interpret results
if p < alpha:
    print("\nConclusion: Reject H0. There is an effect between gender and nobility.")
else:
    print("\nConclusion: Fail to reject H0. There is no significant effect between gender and nobility.")
```

```

plt.xlabel("Allegiance")
plt.ylabel("Number of Deaths")
plt.xticks(rotation=45)
plt.legend(title="Sex")
plt.show()

#statistical analysis
#CHI-SQUARE test
'''
H0: Gender has no effect on Nobility.
H1: Gender has an effect on Nobility.
'''

from scipy.stats import chi2_contingency
# Define a function to perform Chi-square test
def chi_square_test(feature1, feature2, alpha=0.05):
    contingency_table = pd.crosstab(got_prep[feature1], got_prep[feature2])
    chi2, p, dof, expected = chi2_contingency(contingency_table)
    #return chi2, p
    print(f"{feature1} vs {feature2}:")
    print(f"Chi-square statistic: {chi2}")
    print(f"P-value: {p}")
    print(f"Degrees of freedom: {dof}")
    print(f"Expected frequencies:\n{expected}")

# Interpret results
if p < alpha:
    print("\nConclusion: Reject H0. There is an effect between gender and nobility.")
else:
    print("\nConclusion: Fail to reject H0. There is no significant effect between gender and nobility.")

```

ANALIZA STATISTICĂ A PERSONAJELOR DIN GAME OF THRONES

```
# Gender vs Nobility
chi_square_test('Gender', 'Nobility')

#print(f"Gender vs Nobility: Chi-square statistic: {chi2}, P-value: {p}")

import scipy.stats as stats

#ANOVA
'''
H0: There are no significant differences in Book Intro Chapter across different
Allegiances.

H1: There are significant differences in Book Intro Chapter across different
Allegiances.
'''

#clean the dataset
filtered_data = got_prep.dropna(subset=['Book Intro Chapter', 'Allegiances'])

# group by allegiances
grouped_data = [filtered_data[filtered_data['Allegiances'] == allegiance]['Book
Intro Chapter']

                for allegiance in filtered_data['Allegiances'].unique()]

# Perform one-way ANOVA
f_stat, p_value = stats.f_oneway(*grouped_data)

# Display results
print("ANOVA Results:")
print(f"F-Statistic: {f_stat}")
print(f"P-Value: {p_value}")

# Interpret results
if p_value < 0.05:
    print("\nConclusion: Reject H0. There are significant differences in Book
Intro Chapter across different Allegiances.")
else:
```

ANALIZA STATISTICĂ A PERSONAJELOR DIN GAME OF THRONES

```
print("\nConclusion: Fail to reject  $H_0$ . There are no significant differences in
Book Intro Chapter across different Allegiances.")

#PEARSON'S R TEST

'''
H0: There is no significant correlation between Book of Death and Gender.
H1: There is a significant correlation between Book of Death and Gender.

'''

# Clean dataset for analysis
filtered_data = got_prep.dropna(subset=['Book of Death', 'Gender'])

# Split data
book_of_death = filtered_data['Book of Death']
gender = filtered_data['Gender']

# Pearson's R
r, p_value = stats.pearsonr(book_of_death, gender)

# Display results
print("Pearson's R Test:")
print(f"Correlation Coefficient (R): {r}")
print(f"P-Value: {p_value}")

# Interpret results
if p_value < 0.05:
    print("\nConclusion: Reject  $H_0$ . There is a significant correlation between
Book of Death and Gender.")
else:
    print("\nConclusion: Fail to reject  $H_0$ . No significant correlation between
Book of Death and Gender.")
```